

APRESENTAÇÃO DE PROJETO - GRUPO 12

Classificador Semântico de Reviews via Grafos Ponderados

Análise de Perfis de Jogadores na Steam (Subnautica 2)

EQUIPE DE DESENVOLVIMENTO - GRUPO 12

André João • Eric Akio • Jésus Gabriel • Ricardo Lucas • Vinicius dos Santos

Contexto do Projeto

- Volume **massivo** de avaliações geradas constantemente na plataforma Steam.
- Opiniões e críticas expressas em formato de **texto livre** de forma altamente complexa.
- Extrema **dificuldade de análise manual** em tempo real por equipes humanas de desenvolvimento.
- Necessidade crítica e imediata de **extração automática de conhecimento** estratégico.

The screenshot displays the 'Análises de usuários para Subnautica 2' page on a dark-themed website. At the top, there are links for 'Ver detalhamento por idioma', 'Sobre as análises de usuários', and 'Suas preferências'. A summary box shows 'ANÁLISES EM PT-BR: Extremamente positivas (2.627 análises)'. To the right, statistics indicate 'Análises em todos os idiomas: 108.806' and 'Análises recentes em todos os idiomas: 28.757', both marked as 'Muito positivas'. Below this is a 'VAPORLENS HIGHLIGHTS' section with a date '15/05/2026, 05:13:05' and buttons for 'View on VaporLens' and 'Show VaporLens'. A filter bar includes dropdowns for 'Tipo de análise', 'Forma de aquisição', 'Idioma', 'Intervalo de datas', 'Tempo de jogo', and 'Ordem de exibição', along with an 'Exibir gráfico' button. The language is set to 'Português (Brasil)'. A message states 'Exibindo 2.789 análises que correspondem aos filtros acima (Extremamente positivas)'. The main content is divided into two columns: 'ANÁLISES MAIS ÚTEIS' and 'ANÁLISES MAIS RECENTES'. The 'Mais Úteis' section features a recommendation by 'Yuu_kk' (22 jogos, 2 análises) with a 'Recomenda' badge. The analysis text describes a multiplayer experience and includes a section for 'Especificações do computador' (Windows 11, AMD Ryzen 5 4600G, Radeon Graphics, 16 GB RAM, AMD Radeon RX 7600, 8 GB VRAM). It also shows a utility rating with '41 pessoas acharam esta análise útil' and '26 pessoas acharam esta análise engraçada'. The 'Mais Recentes' section shows three recent analyses by 'GUSTAVO' (17,5 horas), 'XZJulio' (25 horas), and 'Vardinho00' (15,7 horas), all marked as 'ANÁLISE DE ACESSO ANTECIPADO'.

O Problema Central



Sobrecarga de Informação

O volume astronômico inviabiliza o acompanhamento e filtro humano de forma ágil.



Perfis de Jogadores Distintos

Cada tipo de jogador valoriza um aspecto específico do jogo no momento da review.



Interpretações Diferentes


A mesmíssima experiência causa percepções completamente conflitantes entre usuários.



Classificação Automática

Urgência por um sistema inteligente capaz de catalogar sistematicamente o estilo de escrita.


Visão Geral da Solução



Pipeline direcional: Do dado não estruturado à inferência categórica final de perfil.

Estrutura do Grafo

- ◆ Grafo estruturado de forma **direcionada e ponderada**.
- ◆ Arquitetura projetada em formato estritamente **hierárquico**.
- ◆ Foco integral em **organização semântica** rica de tópicos e domínios.
- ◆ Sistemáticamente baseado no **vocabulário real** extraído das reviews.



Níveis do Grafo



Categorias Principais (Target)

As raízes fundamentais da classificação (os três grandes arquétipos visados no projeto).



Subcategorias

Nodos intermediários que agregam conjuntos afins de termos correlacionados semanticamente.



Palavras-chave (Tokens)

Palavras reais extraídas das análises após limpeza de ruído, stop-words e pré-processamento clássico.

Fluxo Bottom-Up: Dos dados literais à abstração conceitual.

Categorias Principais



Casual / Imersivo

Foco total na história, imersão ambiental, beleza dos biomas alienígenas profundos, narrativa e modo co-op.



Técnico / Performance

Foco voltado a bugs, desempenho de hardware, Unreal Engine 5, FPS, otimização de sistema e drivers.



Hardcore / Sobrevivência

Foco em gerenciamento estrito de oxigênio/recursos, grind de crafting complexo, mecânicas de combate e sobrevivência extrema.

Arestas e Pesos

- ✦ Arestas representam a **conexão lógica** direta entre os níveis semânticos mapeados.
- ✦ Os pesos são modelados com base estrita na **frequência absoluta (TF)** das palavras.
- ✦ Utilização da técnica de **Suavização Laplaciana** para prevenir pesos nulos nas interações.
- ✦ Estabilidade matemática que dita diretamente a **intensidade da propagação** no grafo.

CÁLCULO DO PESO

$$\text{Peso}_{\text{Aresta}} = \text{TF} + 1$$

 A suavização garante conexões de segurança no percurso.

Exemplo Visual do Grafo : Categoria Casual / Imersivo




Exemplo de relações estruturadas no grafo com todas as categorias, subcategorias e palavras-chave de demonstração, sem dados de quantidade.

Estratégia Geral



Teoria dos Grafos

O ecossistema completo de vocabulário do jogador torna-se um mapa direcionado e navegável.



Inferência Semântica

Extração do sentido real da opinião por meio de análises puramente estruturais e hierárquicas.



Acúmulo de Energia

Termos ativos enviam sua energia de forma combinada e incremental para suas respectivas raízes.



Classificação Automática

A formulação matemática dita a ponderação das categorias sem intervenção manual de terceiros.

Busca em Largura (BFS)


- ✦ **Travessia por camadas:** Visita todos os nodos vizinhos de um nível antes de se aprofundar.
- ✦ Garante um **percurso estritamente organizado** e uniforme ao longo do grafo semântico.

COMPLEXIDADE DE TEMPO

$$O(V + E)$$


COMPLEXIDADE DE ESPAÇO

$$O(V)$$




Spreading Activation

- ✦ **Ativação dos vértices:** Os tokens identificados nas análises recebem energia de inicialização unificada (Valor = 1).
- ✦ **Propagação de energia:** A carga viaja pelas arestas por meio das camadas da BFS.
- ✦ **Multiplicação pelos pesos:** A energia é multiplicada de forma transitiva ao longo de cada arco.
- ✦ **Acúmulo nas categorias:** A soma total dos inputs convergentes estabelece o valor da raiz.



Pipeline de Execução



Implementação Geral



Python 3

DESENVOLVIDO INTEGRALMENTE DO ZERO

SEM NETWORKX

SEM NLTK

SEM SPACY

Estruturas de Dados

Estrutura Principal

- ◆ **Grafo:** Classe orientada a objetos projetada nativamente.
- ◆ **Lista de adjacência:** Usada na gestão limpa das relações entre vértices.
- ◆ **Arrays paralelos:** Utilizados na manipulação linear e veloz em memória física.

Estrutura Auxiliar

- ◆ **Fila FIFO:** Classe queue clássica de apoio ao caminhamento.
- ◆ Garante a ordem sequencial exigida pela **Busca em Largura (BFS)**.
- ◆ Respeito rígido às **diretrizes do trabalho**

Arquitetura Modular

`extrator_dados_steam.py`

Módulo responsável pelo consumo bruto, sanitização e persistência inicial dos dados coletados da API Steam.

`estrutura_dados.py`

Abstração das classes básicas do Grafo, Fila e Lista de Adjacência para uso comum no projeto.

`classificador_bfs.py`

Mecanismo principal contendo as regras de propagação de energia através do algoritmo BFS.

`auditoria_grafo.py`

Mapeador de rastreabilidade (XAI) para detalhar qual caminho e pesos causaram a rotulação final.

Desafíos Encontrados (Parte 1)

Extração das Reviews

Rate-limiting agressivo imposto pelas APIs oficiais e complexidade no scraping de textos brutos sem formatação padronizada.

Construção Manual do Grafo

Esforço humano complexo e demorado na curadoria inicial de palavras para formar um mapeamento semântico consistente e robusto.

Indexação sem Estruturas Hash

Restrição do trabalho de uso de Hashes nativos exigiu o desenvolvimento manual de buscas lineares puras sobre arrays estruturados $O(N)$.

Tratamento de Textos Curtos

Reviews vazias ou de poucas letras (ex: "bom jogo") sem massa de vocabulário resultando em saídas de classificação indefinida.

Desafíos Encontrados (Parte 2)

Definição dos Pesos

Ajuste matemático preciso para normalizar a frequência bruta de tokens em coeficientes estatísticos consistentes na propagação.

Balanceamento das Categorias

Prevenção sistemática de distorções em favor da categoria que possuía o maior volume original de termos mapeados.

Ajuste do Limiar de 30%

Descoberta do ponto limiar perfeito via estudos empíricos para possibilitar uma atribuição realista de rótulos.

Controle de Classificações Múltiplas

Regulação do algoritmo para permitir múltiplos rótulos por review exclusivamente em cenários de real ambiguidade.

Exemplo Prático 1 (Mono-Rótulo)

auditoria_grafo.py

[TEXTO SELECIONADO - ID 2135]:

"Excelente jogo, mantem a essencia dos anteriores sem ser repetitivo, o ponto que a historia para e meio cruel porque quero ver mais. Excelente."

Iniciando Auditoria Passo a Passo para os tokens: ['excelente', 'jogo', 'mantem', 'essencia', 'anteriores', 'sem', 'repetitivo', 'ponto', 'historia', 'meio', 'cruel', 'quero']

[Token Processado]: 'historia' (Energia Inicial = 1)

-> Propagando de 'historia' para 'Exploradores Narrativos' (Peso da Aresta: 431) => Energia Acumulada: 431

-> Propagando de 'Exploradores Narrativos' para 'CASUAL / IMERSIVO' (Peso da Aresta: 1) => Energia Acumulada: 431

-> Chegou à Raiz [CASUAL / IMERSIVO] depositando +431 pontos!

PONTUAÇÃO BRUTA E PERCENTUAIS:

Casual = 431 pts (100.0%)

Técnico = 0 pts (0.0%)

Hardcore = 0 pts (0.0%)

-> Tokens Validados no Grafo: ['historia']

-> CLASSIFICAÇÃO FINAL : Casual

Exemplo Prático 2 (Multi-Rótulo)

auditoria_grafo.py

Digite a sua review: O sistema de sobrevivência é excelente, exigindo gerenciamento constante de recursos, exploração cuidadosa e enfrentamento de criaturas perigosas. Ao mesmo tempo, a experiência é fortemente marcada por problemas técnicos, como quedas de FPS, bugs, falhas de carregamento e limitações de otimização da engine.

PONTUAÇÃO BRUTA E PERCENTUAIS:

Casual = 398 pts (38.3%)

Técnico = 446 pts (42.9%)

Hardcore = 195 pts (18.8%)

-> Tokens Validados no Grafo: ['sobrevivencia', 'recursos', 'exploracao', 'criaturas', 'quedas', 'fps', 'bugs', 'carregamento', 'otimizacao', 'engine']

-> CLASSIFICAÇÃO FINAL : Casual + Técnico

Análise dos Resultados: Estatísticas Gerais



Resultados Finais :

Mapeamento consolidado das métricas de acurácia, volume absoluto de reviews catalogadas com sucesso, percentual de indecisões e taxa global de processamento do algoritmo.

MAPEADAS

1939


INDEFINIDAS

761

EFICIÊNCIA

71 %


Análise dos Resultados: Distribuição das Categorias



Análise dos Resultados: Intersecções Semânticas

ANÁLISE DE INTERSECÇÕES SEMÂNTICAS (Discursos Validados: 1.939)

DIAGRAMA DE VENN DAS CATEGORIAS



DETALHAMENTO DAS INTERSECÇÕES



Total de Intersecções Semânticas: 464 discursos

Análise dos Resultados: Casos de Sucesso

```
=====
BATERIA DE TESTES CONTROLADOS (UNIT TESTS)
=====
```

```
[Teste 1] Entrada: "o oceano é lindo, a história do mundo é maravilhosa e o coop é divertido"
Esperado: Casual
Obtido  : Casual
Status  :  PASSOU
```

```
[Teste 2] Entrada: "que jogo lixo, trava muito, a otimização está um lixo, fps caindo"
Esperado: Técnico
Obtido  : Técnico
Status  :  PASSOU
```

```
[Teste 3] Entrada: "não deixam a gente matar os monstros, mecânica de sobrevivência ruim"
Esperado: Hardcore
Obtido  : Hardcore
Status  :  PASSOU
```

```
[Teste 4] Entrada: "o jogo é muito lindo, mas os bugs estão quebrando o fps na minha ue5"
Esperado: Casual + Técnico
Obtido  : Casual + Técnico
Status  :  PASSOU
```

[TEXTO SELECIONADO - ID 996]:

"Jogo muito divertido para quem curee de jogos de sobrevivencia e uma boa historia, 9,0/10"

Iniciando Auditoria Passo a Passo para os tokens: ['jogo', 'divertido', 'quem', 'curee', 'jogos', 'sobrevivencia', 'boa', 'historia']

[Token Processado]: 'divertido' (Energia Inicial = 1)

-> Propagando de 'divertido' para 'Jogadores Sociais' (Peso da Aresta: 142) => Energia Acumulada: 142

-> Propagando de 'Jogadores Sociais' para 'CASUAL / IMERSIVO' (Peso da Aresta: 1) => Energia Acumulada: 142

-> Chegou à Raiz [CASUAL / IMERSIVO] depositando +142 pontos!

[Token Processado]: 'sobrevivencia' (Energia Inicial = 1)

-> Propagando de 'sobrevivencia' para 'Sobrevivência Pura' (Peso da Aresta: 133) => Energia Acumulada: 133

-> Propagando de 'Sobrevivência Pura' para 'HARDCORE / SOBREVIVÊNCIA' (Peso da Aresta: 1) => Energia Acumulada: 133

-> Chegou à Raiz [HARDCORE / SOBREVIVÊNCIA] depositando +133 pontos!

[Token Processado]: 'historia' (Energia Inicial = 1)

-> Propagando de 'historia' para 'Exploradores Narrativos' (Peso da Aresta: 431) => Energia Acumulada: 431

-> Propagando de 'Exploradores Narrativos' para 'CASUAL / IMERSIVO' (Peso da Aresta: 1) => Energia Acumulada: 431

-> Chegou à Raiz [CASUAL / IMERSIVO] depositando +431 pontos!

PONTUAÇÃO BRUTA E PERCENTUAIS:

Casual = 573 pts (81.2%)

Técnico = 0 pts (0.0%)

Hardcore = 133 pts (18.8%)

-> Tokens Validados no Grafo: ['divertido', 'sobrevivencia', 'historia']

-> CLASSIFICAÇÃO FINAL : Casual

Análise dos Resultados: Limitações Encontradas

[REVIEW INDEFINIDA SORTEADA - ID 1595]

Texto: "muito foda"

Motivo da falha de classificação:

1. Tokens extraídos após limpeza PLN: ['foda']

2. Destes, tokens que existem no Dicionário do Grafo: []

-> CONCLUSÃO: O texto é composto apenas de Stopwords ou jargões não mapeados no Dicionário do Grafo.

[REVIEW INDEFINIDA SORTEADA - ID 1525]

Texto: "literalmente tudo"

Motivo da falha de classificação:

1. Tokens extraídos após limpeza PLN: ['literalmente']

2. Destes, tokens que existem no Dicionário do Grafo: []

-> CONCLUSÃO: O texto é composto apenas de Stopwords ou jargões não mapeados no Dicionário do Grafo.

Análise dos Resultados: Conclusões dos Resultados


CONCLUSÕES: CLASSIFICAÇÃO TEXTUAL COM GRAFOS E BFS EM SUBNAUTICA



Viabilidade da Heurística em Grafos

A travessia hierárquica via BFS provou que conexões semânticas puras conseguem inferir o comportamento do usuário sem a necessidade de modelos estatísticos pesados.

✓ VIÁVEL E LEVE



Validação do Corte Multi-Rótulo (30%)

O limiar provou ser essencial; o discurso real do jogador não é binário e frequentemente mescla imersão narrativa com relatórios técnicos de bugs no mesmo parágrafo.



~~crítico~~
~~bugado~~
~~bugado~~
~~contor~~
~~inknont~~
~~bazari~~
~~QP~~

Vulnerabilidade ao Dicionário Estático

A maior limitação do modelo reside no Nível 0; a ausência de um lematizador faz com que gírias não cadastradas gerem dispersão e perda de energia de ativação.

⚡ SEM ENERGIA



Reflexo Fiel do Domínio

A polarização de disparos entre os nós Imersivo e Técnico espelha a realidade da comunidade de Subnautica: **contemplação do ecossistema versus estabilidade da engine.**



Uso de LLM no Desenvolvimento

- ◆ **Apoio na extração de dados:** Auxílio rápido em códigos de requisição e scraping da API.
- ◆ **Modularização da arquitetura:** Sugestões de acoplamento fraco e clean-code.
- ◆ **Correção e refinamento de código:** Atuação consultiva na depuração de bugs complexos.
- ◆ **Geração de documentação:** Apoio na formatação estruturada de arquivos técnicos.
- ◆ **Melhoria de comentários técnicos:** Polimento e clareza de anotações no código-fonte.
- ◆ **Imagens e correção dos slides:** apoio na geração de imagens ilustrativas para os slides, bem como na revisão e correção do conteúdo em nível gramatical e ortográfico.

A validação, adaptação e integração das soluções propostas pela LLM foram realizadas manualmente pelos alunos.

Conclusão Geral

🎯 Objetivo Alcançado

Classificador em perfeito funcionamento sob as rígidas e complexas restrições técnicas da disciplina.

📊 Resultados Obtidos

Sucesso na identificação e segmentação de perfis em volumetria real.

🔧 Contribuições do Projeto

Prova de conceito demonstrando robustez unindo Grafos e NLP sem o uso de bibliotecas de terceiros.

⚠️ Limitações e Futuro

Dependência estática do dicionário e proposta de inclusão de machine learning e tabelas hash personalizadas.

Obrigado!

Perguntas?



REPOSITÓRIO DO PROJETO

<https://github.com/xGabrielCv/eda2-classificacao-textual-grafos-sub2>